



PROJETO DATA SCIENCE

Chuva na Austrália



O mundo assistiu perplexo ao céu vermelho-sangue sobre a [Austrália](#) que ocorreu no início de 2020 , devido aos milhões de hectares de [área queimada](#) sobre a porção continental da Oceania .

Seca e calor acumulado ocasionaram as queimadas na Austrália, explica especialista

Professor da UFPel que estuda poluição atmosférica escreve sobre a origem dos incêndios e mensura seu impacto em nível global, o que inclui a América do Sul

Objetivo com os dados é a criação de um modelo Machine Learning que seja capaz de mostrar se irá chover ou não baseado nos dias anteriores.

Com esses dados será possível prever possíveis focos de incêndio devido ao excesso de calor e combatê-los antes que se alastrem.



Os dados foram coletados do
Kaggle em formato .csv.

Constam aproximadamente 146
mil registros de 10 anos de 49
cidades Australianas.

kaggle


```

# Column Non-Null Count Dtype
0 Date 145460 non-null object
1 Location 145460 non-null object
2 MinTemp 143975 non-null float64
3 MaxTemp 144199 non-null float64
4 Rainfall 142199 non-null float64
5 Evaporation 82670 non-null float64
6 Sunshine 75625 non-null float64
7 WindGustDir 135134 non-null object
8 WindGustSpeed 135197 non-null float64
9 WindDir9am 134894 non-null object
10 WindDir3pm 141232 non-null object
11 WindSpeed9am 143693 non-null float64
12 WindSpeed3pm 142398 non-null float64
13 Humidity9am 142806 non-null float64
14 Humidity3pm 140953 non-null float64
15 Pressure9am 130395 non-null float64
16 Pressure3pm 130432 non-null float64
17 Cloud9am 89572 non-null float64
18 Cloud3pm 86102 non-null float64
19 Temp9am 143693 non-null float64
20 Temp3pm 141851 non-null float64
21 RainToday 142199 non-null object
22 RainTomorrow 142193 non-null object
dtypes: float64(16), object(7)

```




```
df.isnull().sum() #QTD de Nulos
```

Date	0
Location	0
MinTemp	1485
MaxTemp	1261
Rainfall	3261
Evaporation	62790
Sunshine	69835
WindGustDir	10326
WindGustSpeed	10263
WindDir9am	10566
WindDir3pm	4228
WindSpeed9am	1767
WindSpeed3pm	3062
Humidity9am	2654
Humidity3pm	4507
Pressure9am	15065
Pressure3pm	15028
Cloud9am	55888
Cloud3pm	59358
Temp9am	1767
Temp3pm	3609
RainToday	3261
RainTomorrow	3267
dtype:	int64



Colunas Excluidas

- Cloud3pm
- Cloud9am
- Sunshine
- Rainfall
- Evaporation

Nulos



Colunas Normalizadas

- Tempmin
- Tempmax
- WindGus
- WindGus9
- WindGus3
- Humidity
- Humidity9
- Humidity3
- Pressure9
- Pressure3
- Temp9
- Temp3

112.925
registros



Modelo 01

100 épocas

0.01 Taxa de
Aprendizado

64 batch

02 Camada de Entrada
07 Neurônios

Camada Intermediária
Transformação Linear 05
Neurônios

01 Neurônios de Saída

Melhor
Modelo

Modelo 01

100 épocas

0.01 Taxa de
Aprendizado

64 batch

Modelo 02

119 épocas

0.01 Taxa de
Aprendizado

64 batch

Modelo 03

075 épocas

0.02 Taxa de
Aprendizado

64 batch

Modelo 01

```
[59] print(resultado_1) #melhor hiperparametros
```

	precision	recall	f1-score	support
0	0.94	0.76	0.84	17581
1	0.50	0.81	0.62	5004
accuracy			0.77	22585
macro avg	0.72	0.79	0.73	22585
weighted avg	0.84	0.77	0.79	22585

Modelo 02

```
[60] print(resultado_2)
```


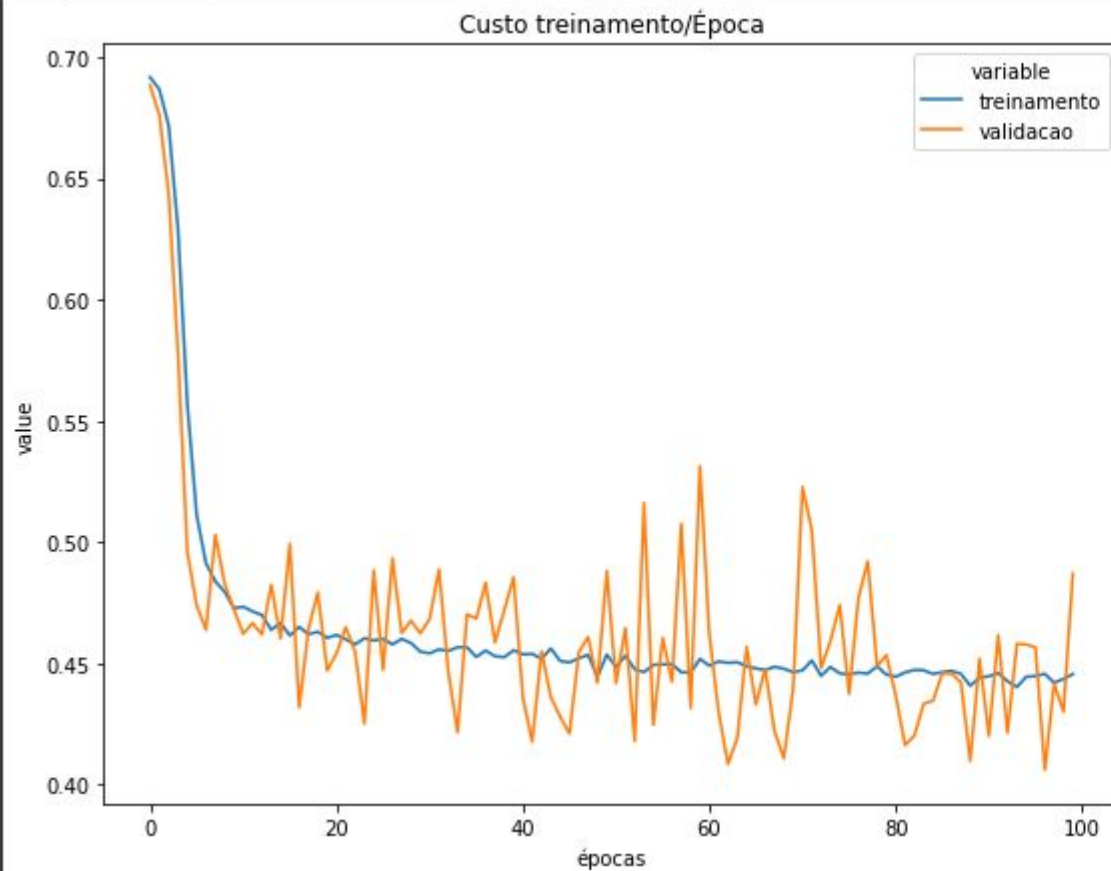
	precision	recall	f1-score	support
0	0.92	0.82	0.87	17581
1	0.55	0.76	0.64	5004
accuracy			0.81	22585
macro avg	0.74	0.79	0.75	22585
weighted avg	0.84	0.81	0.82	22585

Modelo 03

```
[61] print(resultado_3)
```


	precision	recall	f1-score	support
0	0.93	0.80	0.86	17581
1	0.53	0.78	0.63	5004
accuracy			0.80	22585
macro avg	0.73	0.79	0.74	22585
weighted avg	0.84	0.80	0.81	22585

Modelo 01




Modelo 02

Custo treinamento/Época v2



Acurácia treinamento/Época v2



Modelo 03

